张子扬

邮箱：ziyang-z24@mails.tsinghua.edu.cn | 主页：windowso.github.io | GitHub：github.com/windowso | 北京

清华大学电子工程系博士生。研究方向：时序大模型与世界模型、语音生成（TTS、语音大模型）、大模型对齐（DPO、弱到强泛化）

教育背景

清华大学　电子工程系　博士在读 2024.08 – 至今
导师：张超副教授 北京

清华大学　电子工程系　工学学士 2020.09 – 2024.07
清华大学优良毕业生（2024）；学业优秀奖学金（2020–2023，共三次） 北京

实习经历

上海人工智能实验室 2024.11 – 2026.10
研究实习生，书生 Intern-S 系列时序团队；以下时序方向工作均在实习期间完成

书生 Intern-S1：科学多模态基础模型（241B MoE）　时序模态负责人　技术报告 2025

背景与目标 科学数据中大量信息以原始数值信号的形式存在（地震波、引力波、天文光变曲线、脑电等），采样率从每天一个点到 GHz 级不等。目标是让科学基础模型直接读取原始时序信号，作为图像之外的又一科学模态，支持理解与推理。

方法与结果 在 28B 激活 / 241B 总参数、继续预训练 5T token 的 MoE 多模态模型中新增时序模态：自适应降采样模块 + Transformer 编码块，把跨越多个数量级采样率的原始信号压缩成便于 LLM 理解和推理的表示，与文本、视觉模态统一训练。

我的职责 负责时序模态的整体架构设计与模型训练：时序编码器设计、时序与 LLM 的跨模态对齐和 SFT；基于实验室 XTuner 训练框架，完成时序模态在 241B 主模型上的合版训练。

书生 Intern-S2-Preview：科学智能体基础模型（397B）　时序模态负责人，预测能力架构独立负责　技术报告 2026

背景与目标 Intern-S1 的时序能力以理解为主。Intern-S2 需要处理更长、频率更高的科学信号，并新增时序预测能力：在对话中读懂预测指令，自行确定预测长度并输出未来数值序列。

方法与结果 长序列编码器：分块后做压缩式 patching（通道归一化、CNN 局部特征、Q-Former 时间压缩），再经通道间 Transformer 建模多通道依赖；相比 Intern-S1-Pro，最大输入长度由约 24 万提升到 30 万时间步，最长输入下推理速度提升约 5–6 倍、显存降至约 20%，并新增 MHz 级雷达信号。预测分支：Q-Former 汇聚 LLM 语义与编码器数值表示，以交叉注意力条件化因果 Transformer 预测器，再由预测长度模块读取指令决定输出长度。SciTS 理解任务在双方都支持的 9 个任务中有 7 个超过 Intern-S1-Pro（PHU01 F1 由 36.8 提升到 66.9）；预测任务在多数任务上优于 TimeOmni 和专用时序模型，预测长度判断准确率 99%，GIFT-Eval 零样本 MASE 0.785。

我的职责 负责时序模态整体架构与模型训练（合版）；新增的时序预测能力从 0 到 1 的整体架构探索由我独立负责。

MMTA & TimeOmni-v：时序、文本与视觉的多模态时序分析　一作　**NeurIPS 2026**

背景与目标 时序分析正走向多模态，但现有基准大多把时序与文本、或与同一信号画出的图配对，尚未检验多模态大模型（MLLM）能否把时序与真实世界的视觉证据结合起来。例如判断机器人是否正确完成任务，需要同时依据语言指令、第一视角视频和关节轨迹。

方法与结果 构建三模态基准 MMTA：覆盖机器人、自动驾驶、医疗、金融、气候等 9 个领域，分视频 + 时序与图像 + 时序两种布局，测试集 3,524 条（分类与预测），采用对答错和生成失败都扣分的成功率加权指标。评测 8 个开源与闭源 MLLM，发现共同瓶颈：把时序转成文本会产生极长的 token 序列，并削弱与视觉证据的细粒度对齐。据此提出 TimeOmni-v：在 Qwen2.5-Omni 的基础上增加时序编码器和预测头，原生支持时序模态；用时序专用的 RoPE 把时序与视频对齐到同一时间轴，并让时序 token 与视频帧交错排布。分类平均 swF1 0.601，最强基线 Gemini-3-Flash 为 0.442；在机器人长视频任务上时序 token 减少 232.8 倍，推理加速 23 倍。

SciTS & TimeOmni：科学时序理解与生成　二作　**ICLR 2026**

背景与目标 科学时序长度跨越 7 个数量级（最长达千万点），采样频率最高达 10 MHz。现有做法把时序转成文本或图像：前者序列过长，后者损失数值精度，难以支撑全面的科学时序理解与生成。目标是建立覆盖理解与生成的科学时序基准，并验证把时序作为独立模态的统一模型。

方法与结果 构建 SciTS 基准（12 个学科、43 个任务、54,023 条样本，覆盖异常检测、分类、问答与预测、插补、合成等），系统评测文本 LLM、多模态 LLM 与时序模型共 17 个模型，发现通用 LLM 比专用时序模型泛化更强。提出理解与生成一体的时序大模型 TimeOmni，在理解和生成任务上的平均排名均为第一。

我的职责 独立负责 TimeOmni 的模型架构设计与训练：用 router 按信号长度把时序路由到不同的时序编码器，使模型能处理长度跨度极大的多样时序；编码结果经 patch 重编程映射到 LLM 表示空间，生成任务由预测头直接输出数值；基于 Qwen3-8B 完成理解与生成的联合训练。

TimeOmni-o1：双向耦合时序基础模型与 LLM，用于多模态推理与预测　一作　预印本

背景与目标 现实中的时序常伴随文本（如影响它的事件报告），理解（输出文本）和预测（输出时序）都需要联合推理两种模态。LLM 把时序读成数字 token，难以处理长序列；时序基础模型（TSFM）预测能力强，但不能读写文本；现有时序语言模型在 LLM 侧做预测，没有用上 TSFM 的预训练预测能力。

方法与结果 提出 TimeOmni-o1，双向耦合预训练 TSFM 与 LLM：TSFM 把时序压缩编码给 LLM，LLM 结合文本用文字推理；推理结果再回传给 TSFM，作为条件生成预测。构建带推理链标注的 MMTR 数据集（12 个领域、50 万余条）。理解平均 84.2（最强基线 74.9），预测 CRPS 0.116，在所有领域最低，也优于单独使用其内部的 LLM 或 TSFM；在 3 个公开基准上超过各基准报告的专用时序模型。

Time-JEPA：用物理时序约束视频世界模型 共同一作

背景与目标 现有世界模型主要依赖视频训练，但真实世界不只有视频，还有速度、关节角、力等各种时序物理量，以及其背后的物理规律。物理规律（如牛顿定律）建立在对物理量的精确测量之上，世界模型要更准确地理解物理规律，就需要捕捉高精度、动态的时序物理量表征；而只用视频训练的世界模型更擅长捕捉画面中的语义信息，很难学到这类表征。目标是把时序物理量引入世界模型训练。

方法与结果 提出 Time-JEPA，用与视频时间对齐的低维物理时序（传感器通常随视频同步采集）作为 V-JEPA 微调的辅助监督，评测时只输入视频。在自动驾驶、机器人操作、人体运动三个领域，模型对物理规律的拟合更好（按运动学重建的轨迹误差 4.150 m 降至 1.858 m）；在未见条件和未见状态变量两级分布外设定下，当前状态解码与多步未来状态预测均稳定提升；对物理异常更敏感，并能泛化到未见场景。

我的职责 提出研究构想，设计整体方法与核心技术方案，确定使用的数据集和预期结论；指导低年级同学完成实验。

Apple，Siri 中国研发团队 2024.01 – 2024.10

研究实习生，语音生成

BELLE：贝叶斯语音合成器可以向多个教师学习 一作 arXiv 2025

背景与目标 语音合成本质上是“一对多”映射，同一段文本有多种合理读法，带有内在不确定性；现有连续值自回归 TTS 依赖固定方差先验，只能给出静态的点估计，忽略了自然语音的动态变化。目标是在不增加参数和推理延迟的前提下，用贝叶斯方法显式建模这种不确定性。

方法与结果 提出 BELLE，把贝叶斯证据学习引入连续值自回归 TTS，用 Normal-Inverse-Gamma 分布建模每帧声学目标，按上下文动态预测方差，刻画数据相关的偶然不确定性；训练数据由真实录音（LibriSpeech 约 706 小时）和 6 个开源 TTS 系统的合成数据组成，共约 4.8k 小时。LibriSpeech test-clean 跨句合成 WER 2.45%、说话人相似度 SIM 0.641（同数据训练的 MELLE 为 3.30% / 0.606）；主观评测 MOS 4.21、SMOS 4.13（对比模型中最高）。流式版本 BELLE-stream WER 3.54%（SMLLE 为 5.14%），首包延迟约 440 ms，RTF 0.55。

其他研究

TVPara：复杂声学环境下的电视剧语音副语言描述 一作 arXiv 2026

背景与目标 音频大模型难以解析强烈情绪与复杂声学环境并存的语音中的副语言信息（情绪、语速、音高等）；现有语料多为录音棚语音，情绪与声学多样性有限，少数野外语料也只有类别标签，缺少自由文本描述。

方法与结果 基于电视剧构建副语言描述数据集 TVPara，经音频大模型预标注与人工精校，包含单句（约 492 小时）和新提出的多句（约 213 小时）两个任务，后者描述相邻语句间副语言属性的变化。微调开源音频大模型后，复杂声学环境下的副语言理解平均相对提升 31.26%，并泛化到未见剧集和更干净的跨域语音。

Bayesian WeakS-to-Strong：从文本分类到生成 共同一作 **ICLR 2025**

背景与目标 AI 的能力终将超越人类，届时人类如何有效监督比自己更强的 AI？我们提出利用人类的集体智慧，用多个监督者模拟人类意见的多样性。由于当时还没有如此强大的 AI，我们用多个小模型模拟人类、用更大的模型模拟超级智能。如今这一预期已经成为现实，AI 已在数学、代码等多个领域超越人类。

方法与结果 以多个弱模型的集成作为监督者，用贝叶斯证据学习（Dirichlet 先验）估计弱标签的置信度来指导强模型训练；再借助 token 级软标签推广到生成任务，并结合弱模型偏好做（保守）DPO。SciQ 分类上性能差距恢复率达 0.828（基线 0.754），SLURP 生成任务上为 0.668，加入保守 DPO 后达 0.705。

我的职责 提出核心 idea；完成分类任务上的方法实现与实验，给出初步可行性验证；生成任务的扩展由合作同学完成。

SWIM：短窗 CNN 与 Mamba 结合的脑电听觉空间注意力解码 一作 **IEEE SLT 2024**

背景与目标 在多人同时说话的场景中，听觉空间注意力解码（ASAD）直接从脑电判断听者关注左侧还是右侧的说话人，不依赖干净语音，是神经调控助听设备的关键环节；它既要在短时窗内快速响应注意力切换，又要利用长时脑电中的信息。

方法与结果 提出短窗 CNN（SW_CNN），结合脑电数据增强、多任务训练和模型融合，在 KUL 数据集留一说话人设定下准确率达 84.9%，比此前最佳结果绝对提升 4.9%；再用 Mamba 整合长时历史信息得到 SWIM，准确率 86.2%，分类错误相对降低 31.0%，三种评测设定均刷新最佳结果。

论文发表

* 表示共同一作

[1] **Ziyang Zhang***, S. Li*, Y. Wang, Z. Cui, B. Zhou, W. Wu, C. Zhang. MMTA: Benchmarking Multimodal Temporal Analysis with Time Series, Text, and Vision. **NeurIPS 2026**. arXiv

[2] W. Wu, **Ziyang Zhang**, L. Liu, X. Xu, et al., C. Zhang. SciTS: Scientific Time Series Understanding and Generation with LLMs. **ICLR 2026**. paper

[3] Z. Cui*, **Ziyang Zhang***, G. Sun, W. Wu, C. Zhang. Bayesian WeakS-to-Strong from Text Classification to Generation. **ICLR 2025**. paper

[4] **Ziyang Zhang**, A. Thwaites, A. Woolgar, B. Moore, C. Zhang. SWIM: Short-Window CNN Integrated with Mamba for EEG-Based Auditory Spatial Attention Decoding. **IEEE SLT 2024**.

[5] **Ziyang Zhang**, S. Li, W. Wu, C. Zhang. TimeOmni-o1: Bidirectionally Coupling Time Series Foundation Models and LLMs for Multimodal Reasoning and Forecasting. OpenReview

[6] S. Li*, **Ziyang Zhang***, W. Wu, M. Liu, C. Zhang. Time-JEPA: Grounding Video World Models with Physical Time Series. OpenReview

[7] **Ziyang Zhang**, W. Yu, W. Wu, X. Xu, C. Zhang. TVPara: Paralinguistic Captioning of Expressive TV-Series Speech in Complex Acoustic Environments. arXiv 2026. arXiv

[8] **Ziyang Zhang**, Y. Gao, X. Xu, B. Li, W. Wu, C. Zhang. Bayesian Speech Synthesizers Can Learn from Multiple Teachers. arXiv 2025. arXiv

[9] Intern-S2 Team（含 **Ziyang Zhang**）. Intern-S2-Preview: Scientific Agentic Foundation Model. 技术报告, 2026. arXiv

[10] Intern-S1 Team（含 **Ziyang Zhang**）. Intern-S1: A Scientific Multimodal Foundation Model. 技术报告, 2025. arXiv