张子扬

邮箱：ziyang-z24@mails.tsinghua.edu.cn | 主页：windowso.github.io | GitHub：github.com/windowso | 北京

清华大学电子工程系博士生。研究方向：时序大模型（理解、预测、多模态推理）与世界模型、语音生成、大模型对齐

教育背景

清华大学　电子工程系　博士在读 2024.08 – 至今

导师：张超副教授；预计 2029 年毕业 北京

清华大学　电子工程系　工学学士 2020.09 – 2024.07

清华大学优良毕业生（2024）；学业优秀奖学金（2020–2023，共三次） 北京

实习经历

上海人工智能实验室 2024.11 – 2026.10

研究实习生，书生 Intern-S 系列时序团队；以下时序与多模态工作均在实习期间完成

书生 Intern-S2-Preview：科学智能体基础模型（397B）　时序模态负责人 技术报告 2026

背景与目标　在已有时序理解能力的基础上，处理更长、频率更高的科学信号，并新增时序预测能力：在对话中读懂预测指令，自行确定预测长度并输出未来数值序列。

方法与结果　长序列编码器：分块后做压缩式 patching（通道归一化、CNN 局部特征、Q-Former 时间压缩），再经通道间 Transformer 建模多通道依赖；相比上一代 Intern-S1-Pro（万亿参数），最大输入长度由约 24 万提升到 30 万时间步，在最大长度下推理提速约 5–6 倍、显存降至约 20%。预测分支：Q-Former 汇聚 LLM 语义与编码器数值表示，经交叉注意力条件化因果 Transformer 预测器，由预测长度模块读取指令决定输出长度。SciTS 上，理解任务在双方都支持的 9 个任务中有 7 个超过 Intern-S1-Pro（PHU01 F1 由 36.8 提升到 66.9）；7 个预测任务的 MAPE 全部低于我们此前的 TimeOmni（见 SciTS），其中 6 个低于最佳专用时序模型；预测长度判断准确率 99%。

我的职责　负责时序模态的整体架构与模型训练（合版，即并入主模型统一训练）；新增的时序预测能力，由我独立从 0 到 1 完成整体架构探索。

书生 Intern-S1：科学多模态基础模型（241B MoE）　时序模态负责人 技术报告 2025

背景与目标　让科学基础模型直接读取原始数值信号（地震波、引力波、天文光变曲线、脑电等，采样率从每天一个点到 GHz 级），作为图像之外的又一科学模态。

方法与结果　在 28B 激活 / 241B 总参数、继续预训练 5T token 的 MoE 多模态模型中新增时序编码器：自适应降采样 + Transformer 编码块，把原始信号压缩为便于 LLM 推理的表示。

我的职责　负责时序模态的整体架构设计与模型训练：时序编码器设计、时序与 LLM 的跨模态对齐和 SFT；基于实验室 XTuner 训练框架，完成时序模态并入 241B 主模型的合版训练。

MMTA & TimeOmni-v：时序、文本与视觉的多模态时序分析　共同一作（第一署名） **NeurIPS 2026**

背景与目标　时序分析正走向多模态，但现有基准大多把时序与文本、或与同一信号画出的图配对，尚未检验多模态大模型（MLLM）能否把时序与真实世界的视觉证据结合起来。例如判断机器人是否正确完成任务，需要同时依据语言指令、第一视角视频和关节轨迹。

方法与结果　构建三模态基准 MMTA：覆盖机器人、自动驾驶、医疗等 9 个领域（时序含关节轨迹、车辆状态、生命体征），分视频 + 时序与图像 + 时序两种布局，测试集 3,524 条（分类与预测）。零样本评测 8 个开源与闭源 MLLM，发现共同瓶颈：把时序转成文本会产生极长的 token 序列，并削弱与视觉证据的细粒度对齐。据此提出 TimeOmni-v：在 Qwen2.5-Omni 的基础上接入 Chronos-2 时序编码器和预测头，原生支持时序模态；用时序专用的 RoPE 把时序与视频对齐到同一时间轴，并让时序 token 与视频帧交错排布。逐数据集微调后分类平均 swF1 0.601（零样本基线中最强的 Gemini-3-Flash 为 0.442）；同骨干、同预算下把时序转成文本微调的对照在两个长视频任务上显存溢出。在机器人长视频任务 AgiBot 上，相比把时序转成文本输入，时序 token 减少 232.8 倍，单样本推理加速 23 倍。

SciTS & TimeOmni：科学时序理解与生成　二作 **ICLR 2026**

背景与目标　科学时序长度跨越 7 个数量级（最长达千万点），采样频率最高达 10 MHz。现有做法把时序转成文本或图像：前者序列过长，后者损失数值精度，难以支撑全面的科学时序理解与生成。目标是建立覆盖理解与生成的科学时序基准，并验证把时序作为独立模态的统一模型。

方法与结果　构建 SciTS 基准（12 个学科、43 个任务、54,023 条样本，覆盖异常检测、分类、问答与预测、插补、合成等），零样本评测文本 LLM、多模态 LLM 与时序模型共 17 个模型，发现通用 LLM 比专用时序模型泛化更强。提出理解与生成一体的时序大模型 TimeOmni，在 SciTS 上训练后，理解与生成任务的平均排名均列第一。

我的职责　独立负责 TimeOmni 的模型架构设计与训练：用 router 按信号长度选择不同 patch 尺寸（1–2048）的 patch expert 编码器，使编码后长度稳定在 100–200，从而统一处理长度跨度极大的多样时序；编码结果经 patch 重编程映射到 LLM 表示空间，生成任务由预测头直接输出数值；基于 Qwen3-8B 完成理解与生成的联合训练。

TimeOmni-o1：双向耦合时序基础模型与 LLM，用于多模态推理与预测　一作 预印本 2026

背景与目标　现实中的时序常伴随文本（如影响它的事件报告），理解（输出文本）和预测（输出时序）都需要联合推理两种模态。LLM 把时序读成数字 token，难以处理长序列；时序基础模型（TSFM）预测能力强，但不能读写文本；现有时序语言模型在 LLM 侧做预测，没有用上 TSFM 的预训练预测能力。

方法与结果 提出 TimeOmni-o1，双向耦合预训练 TSFM（Chronos-2）与 LLM（Qwen3.5-9B）：TSFM 把时序压缩编码给 LLM，LLM 结合文本用文字推理；推理结果经门控交叉注意力回传给 TSFM，作为条件生成分位数概率预测，端到端可微。构建带推理链标注的 MMTR 数据集（12 个领域、50 万余条），SFT 后对理解任务做 GRPO 强化学习。在 MMTR 测试集上，理解 12 个领域平均 84.2（最强对比 74.9），预测 CRPS 0.116，5 个领域均最低，也优于单独微调其内部的 LLM（0.308）或 TSFM（0.129）；在 3 个公开基准上超过专用时序模型。

Time-JEPA：用物理时序约束视频世界模型 共同一作 arXiv 2026

背景与目标 现有世界模型主要依赖视频训练，但真实世界不只有视频，还有速度、关节角、力等各种时序物理量，以及其背后的物理规律。物理规律（如牛顿定律）建立在对物理量的精确测量之上，世界模型要更准确地理解物理规律，就需要捕捉高精度、动态的时序物理量表征；而只用视频训练的世界模型更擅长捕捉画面中的语义信息，很难学到这类表征。目标是把时序物理量引入世界模型训练。

方法与结果 提出 Time-JEPA，用与视频时间对齐的低维物理时序作为 V-JEPA 2.1 微调的辅助监督，三个领域共享编码器，评测时只输入视频。在自动驾驶、机器人操作、人体运动上，相比同数据纯视频微调的对照，模型对物理规律的拟合更好：未见条件下按运动学重建的驾驶轨迹误差 4.150 m 降至 1.858 m，同分布下多步未来状态预测 R^2 0.296 升至 0.550；在未见条件和未见状态变量两级分布外设定下，当前状态解码均有提升；对物理异常更敏感（GRASP +2.2 个百分点），换用生成式世界模型 iVideoGPT 作骨干同样有效。

我的职责 提出研究构想，设计整体方法与核心技术方案，确定使用的数据集和研究假设；指导低年级同学完成实验。

Apple，Siri 中国研发团队 2024.01 – 2024.10

研究实习生，语音生成

BELLE：贝叶斯语音合成器可以向多个教师学习 一作 arXiv 2025

背景与目标 语音合成是“一对多”问题，同一段文本有多种合理读法，分布的离散程度随输入而变；多数 TTS 模型把它隐含在采样中或预先固定。目标是显式建模这一分布，而估计方差需要同一文本的多条录音。

方法与结果 提出 BELLE，基于证据深度学习对每帧梅尔谱的均值与方差施加 Normal-Inverse-Gamma 先验并由输入预测，保持 MELLE 的结构与单次采样；构建真实录音（ParallelVox，881 小时）与 TTS 合成（LS+6TTS，4,817 小时）两个平行语音语料。同等条件下优于 MELLE：零样本跨句合成 WER-H 2.99% 对 3.83%，SMOS 4.13 对 3.80；流式版本首包延迟中位数 232 ms，RTF 0.31。

其他研究

SWIM：短窗 CNN 与 Mamba 结合的脑电听觉空间注意力解码 一作 **IEEE SLT 2024**

背景与目标 从脑电判断听者关注左侧还是右侧的说话人（不依赖干净语音），服务于神经调控助听设备，需要短时窗内快速响应并利用长时信息。

方法与结果 短窗 CNN 结合数据增强、多任务训练与模型融合，KUL 留一说话人准确率 84.9%（此前最佳 80.0%）；加入 Mamba 整合长时历史后达 86.2%，相对此前最佳错误率降低 31.0%。

Bayesian WeakS-to-Strong：从文本分类到生成 共同一作 **ICLR 2025**

背景与目标 当 AI 能力超越人类，人类如何监督它？我们提出用多个小模型模拟意见多样的人类监督者、用大模型模拟超级智能，研究多个弱监督者如何更好地监督强模型。

方法与结果 用贝叶斯证据学习估计多个弱监督者标签的置信度来指导强模型，并推广到生成任务与保守 DPO；SciQ 分类上性能差距恢复率 0.828（最强基线 0.768）。

我的职责 提出核心 idea；完成分类任务上的方法实现与实验，给出初步可行性验证；生成任务的扩展由合作同学完成。

TVPara：复杂声学环境下的电视剧语音副语言描述 一作 arXiv 2026

背景与目标 音频大模型难以解析强烈情绪与复杂声学环境并存的语音中的副语言信息，现有语料多为录音棚语音且缺少自由文本描述。目标是构建高表现力的副语言描述数据。

方法与结果 基于电视剧，经音频大模型预标注与人工精校构建 TVPara（单句约 492 小时、多句约 213 小时，后者描述相邻语句间的副语言变化）；微调开源音频大模型后副语言理解相比微调前平均相对提升 31.26%，并泛化到未见剧集。

论文发表

* 表示共同一作

[1] **Ziyang Zhang***, S. Li*, Y. Wang, Z. Cui, B. Zhou, W. Wu, C. Zhang. MMTA: Benchmarking Multimodal Temporal Analysis with Time Series, Text, and Vision. **NeurIPS 2026**（Evaluations & Datasets Track）. arXiv

[2] W. Wu, **Ziyang Zhang**, L. Liu, X. Xu, et al., C. Zhang. SciTS: Scientific Time Series Understanding and Generation with LLMs. **ICLR 2026**. paper · code

[3] Z. Cui*, **Ziyang Zhang***, G. Sun, W. Wu, C. Zhang. Bayesian WeakS-to-Strong from Text Classification to Generation. **ICLR 2025**. paper

[4] **Ziyang Zhang**, A. Thwaites, A. Woolgar, B. Moore, C. Zhang. SWIM: Short-Window CNN Integrated with Mamba for EEG-Based Auditory Spatial Attention Decoding. **IEEE SLT 2024**. arXiv

[5] **Ziyang Zhang**, S. Li, W. Wu, C. Zhang. TimeOmni-o1: Bidirectionally Coupling Time Series Foundation Models and LLMs for Multimodal Reasoning and Forecasting. 预印本, 2026. OpenReview

[6] S. Li*, **Ziyang Zhang***, W. Wu, M. Liu, C. Zhang. Time-JEPA: Grounding Video World Models with Physical Time Series. arXiv 2026. arXiv

[7] **Ziyang Zhang**, W. Yu, W. Wu, X. Xu, C. Zhang. TVPara: Paralinguistic Captioning of Expressive TV-Series Speech in Complex Acoustic Environments. arXiv 2026. arXiv

[8] **Ziyang Zhang**, Y. Gao, X. Xu, B. Li, W. Wu, C. Zhang. Bayesian Speech Synthesizers Can Learn from Multiple Teachers. arXiv 2025. arXiv · demo · code

[9] Intern-S2-Preview Team（含 **Ziyang Zhang**）. Intern-S2-Preview: Scientific Agentic Foundation Model. 技术报告, 2026. arXiv

[10] Intern-S1 Team（含 **Ziyang Zhang**）. Intern-S1: A Scientific Multimodal Foundation Model. 技术报告, 2025. arXiv